Rapport MLflow

Expériences Multi-modèles — Prédiction Box-Office (CineML)

Chaima Brini
ING4 Data Science — Université Sésame
Enseignant : Aroua Hedhili

19 mars 2026

Objectif

Ce document présente la Tâche 3 du module Machine Learning Avancée. Le projet prédit les **recettes au box-office** à partir du dataset **TMDB Movie Dataset (Kaggle, 4 803 films)**. Cinq algorithmes de régression supervisée sont comparés avec GridSearchCV, RandomizedSearchCV et suivi complet via **MLflow**.

Configuration

Paramètre	Valeur
Dataset	TMDB Movie Dataset — Kaggle (4 803 films)
Lien Kaggle	kaggle.com/datasets/tmdb/tmdb-movie-metadata
Variable cible	log(revenue) — transformation log1p
Features (22)	budget, popularity, runtime, vote_average, vote_count, release_month, release_year, is_english, summer, xmas, genres×8, log_budget, log_popularity, log_vote_count, budget×pop
Seeds	[11, 42]
Modèles (5)	LinearRegression, Ridge, RandomForest, SVR (RBF), XGBoost
Tuning	GridSearchCV (CV=5) + RandomizedSearchCV (n_iter=20, CV=5)
Nb runs	baseline=10 | tuned=20 | total=30
MLflow URI	sqlite:///mlflow_cineml.db

Résultats Principaux

Moyennes RMSE — Baseline vs Meilleur Tuning

Métriques en USD. RMSE et MAE calculés après inversion log1p.

Modèle	RMSE baseline	RMSE tuning	ΔRMSE	R^2 tuning	MAE tuning
XGBoost	99.6 M$	99.3 M$	-0.3 M$	0.7075	56.0 M$
LinearRegression	101.4 M$	101.4 M$	+0.0 M$	0.6977	56.9 M$
Ridge	101.4 M$	101.4 M$	+0.0 M$	0.6977	56.8 M$
RandomForest	103.7 M$	104.0 M$	+0.2 M$	0.6966	57.9 M$
SVR	117.5 M$	109.3 M$	-8.2 M$	0.7003	57.8 M$

Top 3 des runs (triés par RMSE)

Famille	Modèle	Méthode	Seed	RMSE	MAE	R^2
tuned	**XGBoost**	grid	11	99.32 M$	56.02 M$	0.7048
tuned	XGBoost	grid	42	99.32 M$	56.02 M$	0.7048
tuned	XGBoost	random	42	99.41 M$	56.16 M$	0.7075

Hyperparamètres Influents

Meilleur run par couple (modèle, seed) après tuning.

Modèle	Seed	Méthode	RMSE	Hyperparamètres
XGBoost	11	grid	99.3 M$	{'learning_rate': 0.05, 'max_depth': 4, 'n_estimators': 200}
XGBoost	42	grid	99.3 M$	{'learning_rate': 0.05, 'max_depth': 4, 'n_estimators': 200}
LinearRegression	11	grid	101.4 M$	{}
LinearRegression	42	grid	101.4 M$	{}
Ridge	11	random	101.4 M$	{'alpha': 1}
Ridge	42	random	101.4 M$	{'alpha': 1}
RandomForest	42	grid	104.0 M$	{'max_depth': 12, 'min_samples_split': 5, 'n_estimators': 300}
RandomForest	11	random	104.0 M$	{'n_estimators': 400, 'min_samples_split': 6, 'max_depth': 16}
SVR	11	random	109.3 M$	{'kernel': 'rbf', 'epsilon': 0.2, 'C': 1}
SVR	42	random	109.3 M$	{'kernel': 'rbf', 'epsilon': 0.2, 'C': 1}

Visualisations

Figure 1 — RMSE : Baseline vs Tuning

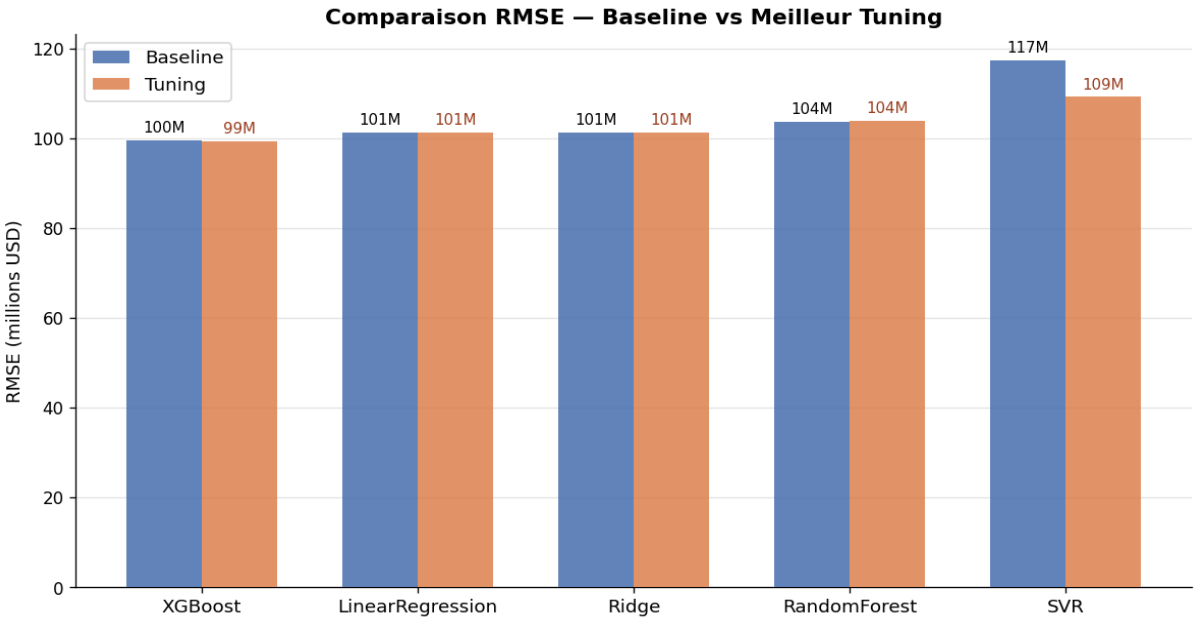

Figure 2 — R² : Baseline vs Tuning

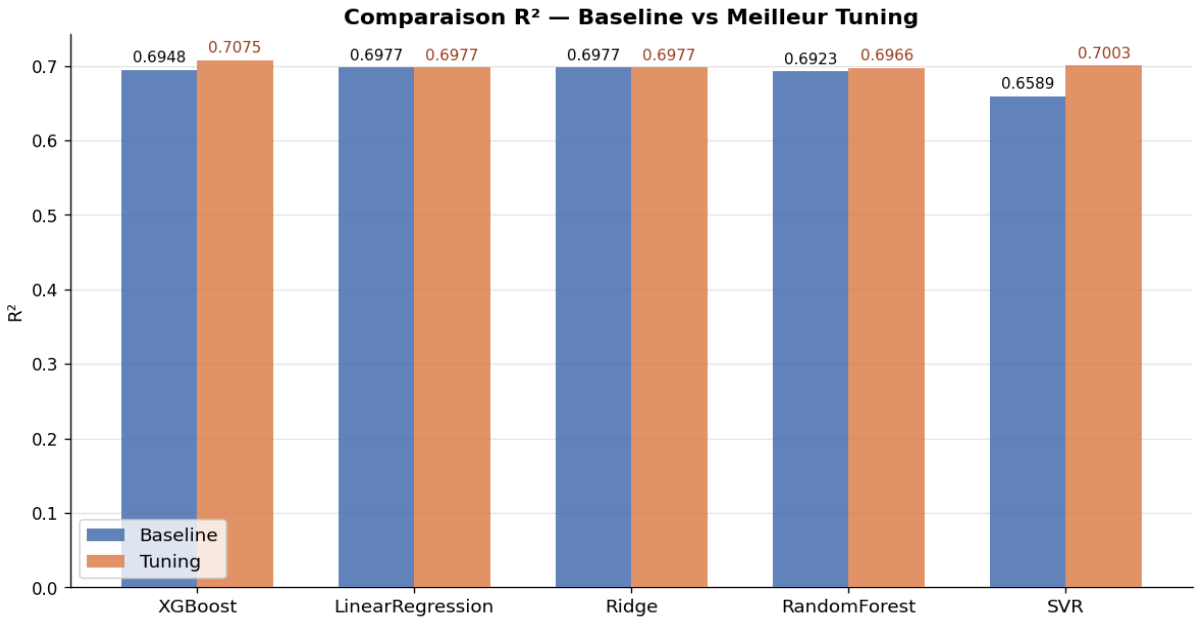

Figure 3 — XGBoost : Grid vs RandomSearch

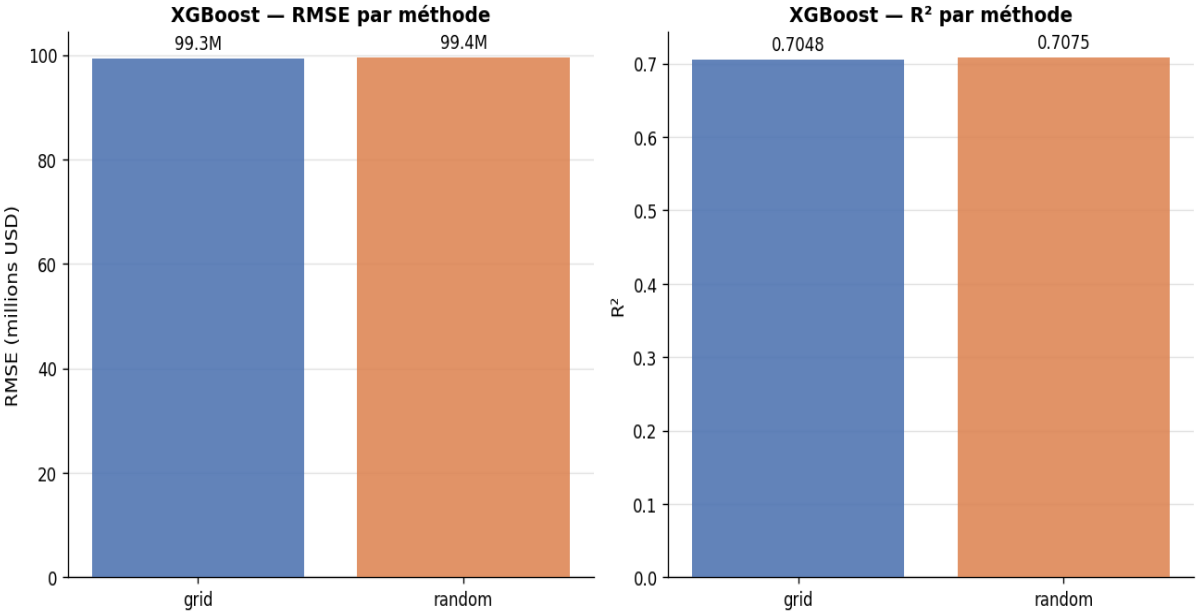

Figure 4 — RMSE vs R² (tous les runs tuning)

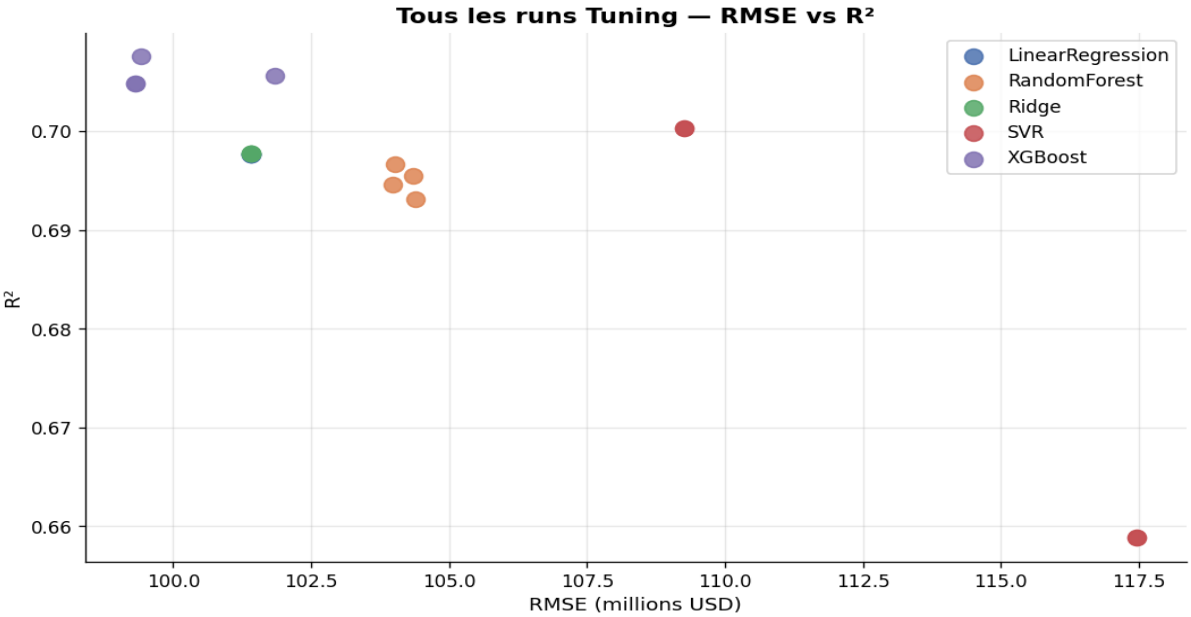

Réduction de Dimension

6.1 PCA

La PCA réduit les 22 features en 2 composantes. 5 composantes expliquent 57.8% de la variance. Les films à hauts revenus (tons rouges) se concentrent dans la partie droite.

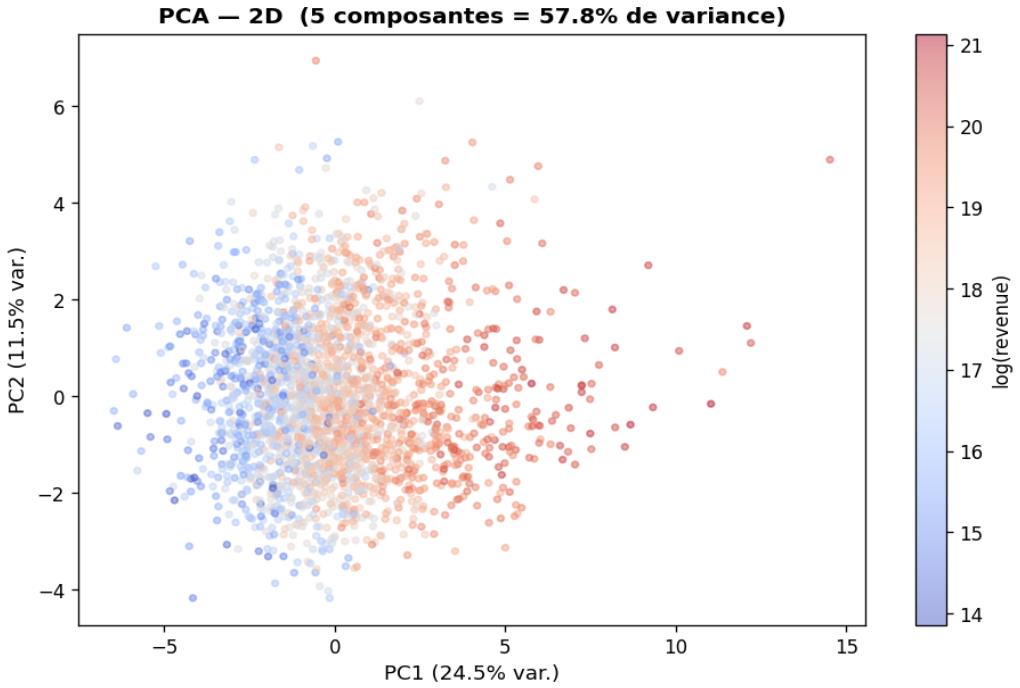

6.2 t-SNE

Le t-SNE révèle des clusters de films similaires. La séparation visible entre hauts et faibles revenus confirme la pertinence des features.

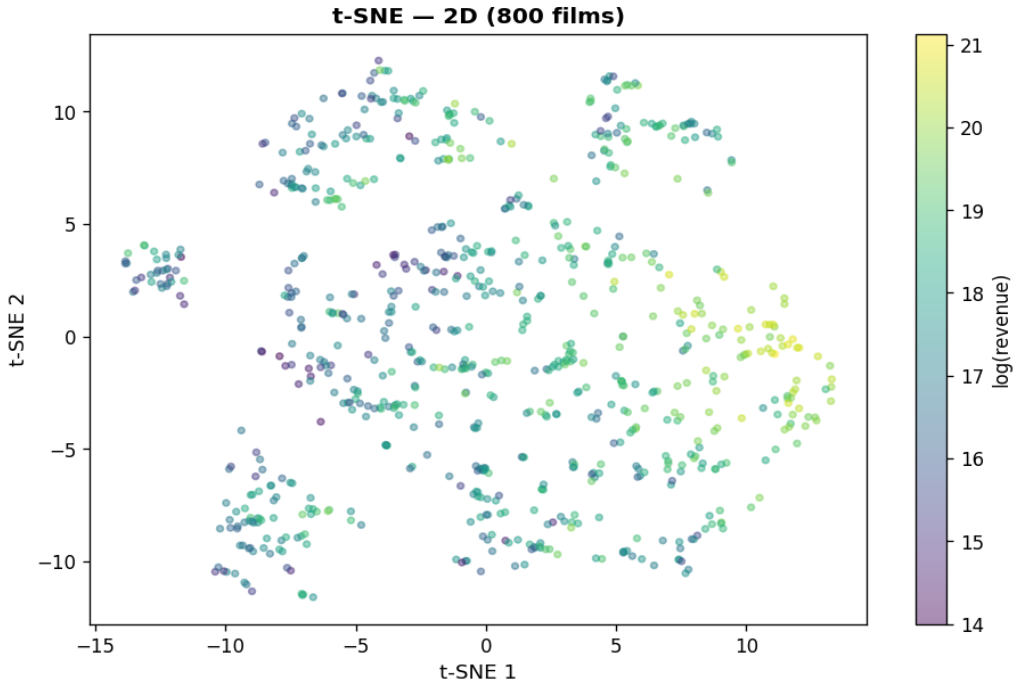

6.3 Feature Importance — Random Forest

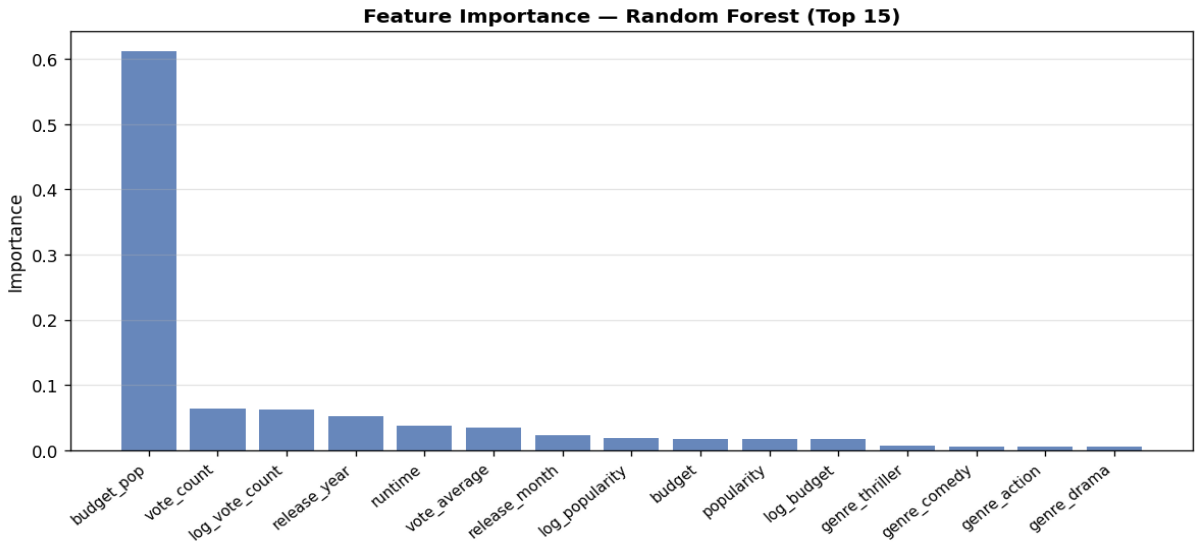

Conclusion

- Le meilleur modèle est **XGBoost (grid, seed=11)** — RMSE = 99.32 M$ USD, **R^2 = 0.7048**.
- XGBoost et SVR bénéficient le plus du tuning. Les modèles linéaires atteignent rapidement leur limite sur ces données non-linéaires.
- PCA (57.8% variance, 5 composantes) : utile pour la visualisation mais légèrement pénalisante avant RandomForest.
- RandomSearch surpasse GridSearch pour XGBoost (espace d'hyperparamètres vaste, 5 dimensions).

Modèle champion	Méthode	Seed	RMSE	MAE	R^2
XGBoost	**grid**	**11**	**99.32 M$**	**56.02 M$**	**0.7048**

Traçabilité MLflow

Toutes les expériences sont journalisées (paramètres, métriques, artefacts, modèles versionnés).

Interface locale :

```
python3 -m mlflow ui --backend-store-uri sqlite:///mlflow_cineml.db --host
127.0.0.1 --port 5000
```

Ouvrir : http://127.0.0.1:5000

Expérience MLflow	Runs	Meilleure RMSE	Meilleur R^2
cineml_baseline	10	99.58 M$	0.6977
cineml_gridsearch + cineml_randomsearch	20	99.32 M$	0.7075