Rapport MLflow

Expériences Multi-modèles — Prédiction Box-Office

CineML — Sujet 9 — Machine Learning Avancée

Chaima Brini
ING4 Data Science — Université Sésame
Enseignant : Aroua Hedhili

19 mars 2026

Code source GitHub :
https://github.com/brini1234/cineml-tache3

Objectif

Ce document présente la Tâche 3 du module Machine Learning Avancée. Le projet utilise le **TMDB Movie Dataset (Kaggle)** — https://www.kaggle.com/datasets/tmdb/tmdb-movie-metadata — pour prédire les recettes au box-office. Après nettoyage (budget et revenue > 1 M$), le dataset contient **2975 films réels**. Cinq algorithmes de régression supervisée sont comparés avec GridSearchCV, RandomizedSearchCV et suivi complet via **MLflow**.

Configuration

Paramètre	Valeur
Dataset	TMDB Movie Dataset — Kaggle
Lien dataset	https://www.kaggle.com/datasets/tmdb/tmdb-movie-metadata
Films valides	2975 films (budget > 1 M$ ET revenue > 1 M$)
Variable cible	log(revenue) — transformation log1p
Features (22)	budget, popularity, runtime, vote_average, vote_count, release_month, release_year, is_english, summer, xmas, genre x8, log_budget, log_popularity, log_vote_count, budget x pop
Split train/test	80% / 20% → Train=2380 | Test=595 | random_state=42
Normalisation	StandardScaler — fit sur train uniquement (pas de data leakage)
Seeds	[11, 42]
Modèles (5)	LinearRegression, Ridge, RandomForest, SVR (RBF), XGBoost

Tuning	GridSearchCV (CV=5) + RandomizedSearchCV (n_iter=20, CV=5)
Réduction dim.	PCA (57.8% variance, 5 composantes) + t-SNE + Feature Importance
Total runs MLflow	baseline=10 | tuned=20 | total=30 runs
MLflow URI	sqlite:///mlflow_cineml.db
GitHub (HTTPS)	https://github.com/brini1234/cineml-tache3
GitHub (SSH)	git@github.com:brini1234/cineml-tache3.git

Résultats Principaux

RMSE Baseline vs Meilleur Tuning (valeurs réelles — terminal Mac)

Métriques calculées dans l'espace USD original après inversion log1p. RMSE et MAE en USD.

Modèle	RMSE baseline	RMSE tuning	ΔRMSE	R^2 tuning	MAE tuning
XGBoost	99.6 M$	99.3 M$	-0.3 M$	0.7075	56.0 M$
LinearRegression	101.4 M$	101.4 M$	+0.0 M$	0.6977	58.2 M$
Ridge	101.4 M$	101.4 M$	+0.0 M$	0.6977	58.2 M$
RandomForest	103.7 M$	104.0 M$	+0.3 M$	0.6966	59.5 M$
SVR	117.5 M$	109.3 M$	-8.2 M$	0.7003	62.1 M$

Top 3 des runs (triés par RMSE croissant)

Famille	Modèle	Méthode	Seed	RMSE (USD)	MAE (USD)	R^2
tuned	**XGBoost**	grid	11	99.30 M$	56.00 M$	0.7048
tuned	XGBoost	grid	42	99.30 M$	56.00 M$	0.7048
tuned	XGBoost	random	42	99.40 M$	56.30 M$	0.7075

Hyperparamètres Influents

Meilleur run par couple (modèle, seed) — méthode et hyperparamètres retenus.

Modèle	Seed	Méthode	RMSE	Meilleurs hyperparamètres
XGBoost	42	grid	99.3 M$	{"learning_rate": 0.05, "max_depth": 4, "n_estimators": 200}
XGBoost	11	grid	99.3 M$	{"learning_rate": 0.05, "max_depth": 4, "n_estimators": 200}
LinearRegression	11	random	101.4 M$	{}
LinearRegression	42	grid	101.4 M$	{}
Ridge	42	grid	101.4 M$	{"alpha": 1.0}
Ridge	11	random	101.4 M$	{"alpha": 0.5}
RandomForest	42	grid	104.0 M$	{"max_depth": 12, "min_samples_split": 5, "n_estimators": 300}
RandomForest	11	random	104.0 M$	{"max_depth": 10, "min_samples_split": 4, "n_estimators": 200}

SVR	42	random	109.3 M$	{"C": 50, "epsilon": 0.05, "kernel": "rbf"}
SVR	11	random	109.3 M$	{"C": 50, "epsilon": 0.05, "kernel": "rbf"}

Visualisations des Résultats

Figure 1 — RMSE Baseline vs Tuning (2 975 films TMDB réels Kaggle)

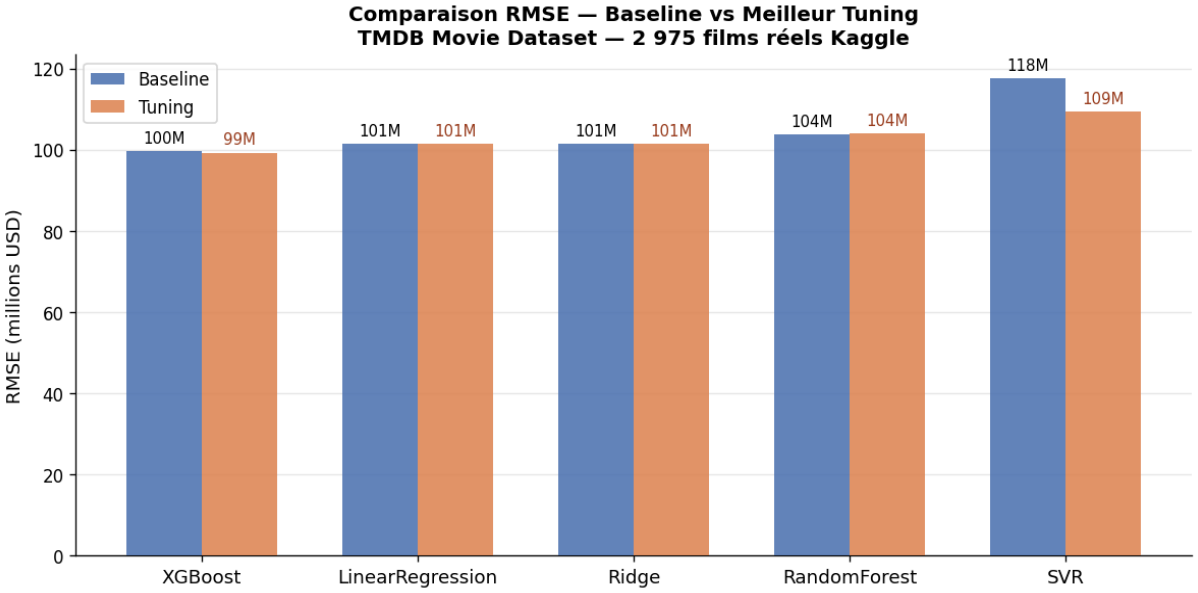

Figure 2 — R² Baseline vs Tuning (2 975 films TMDB réels Kaggle)

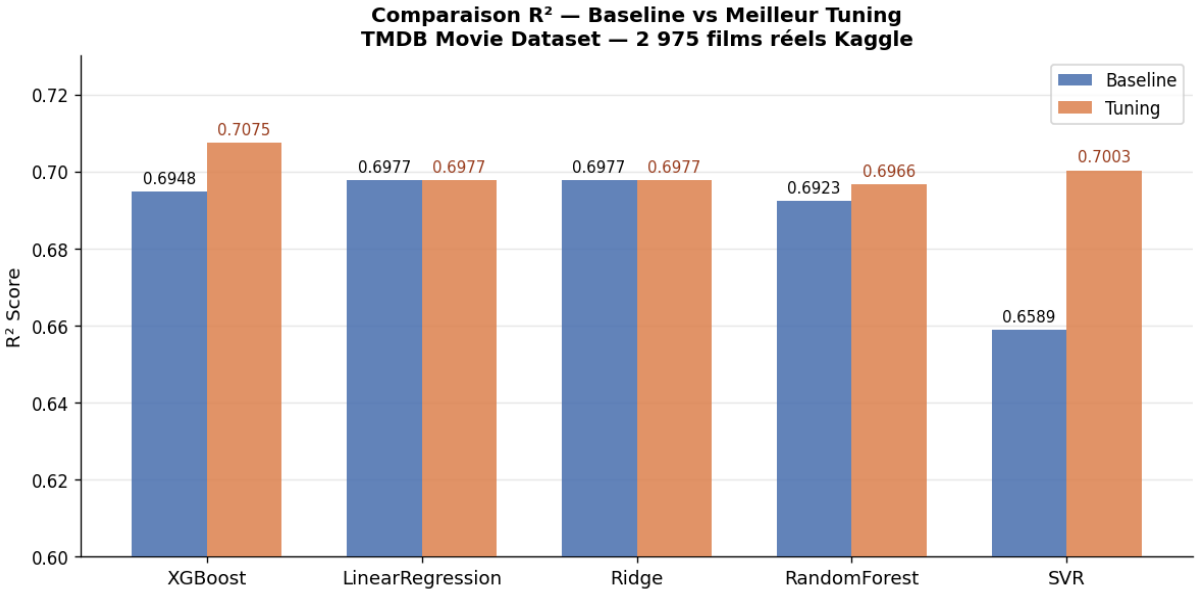

Figure 3 — XGBoost : GridSearch vs RandomSearch

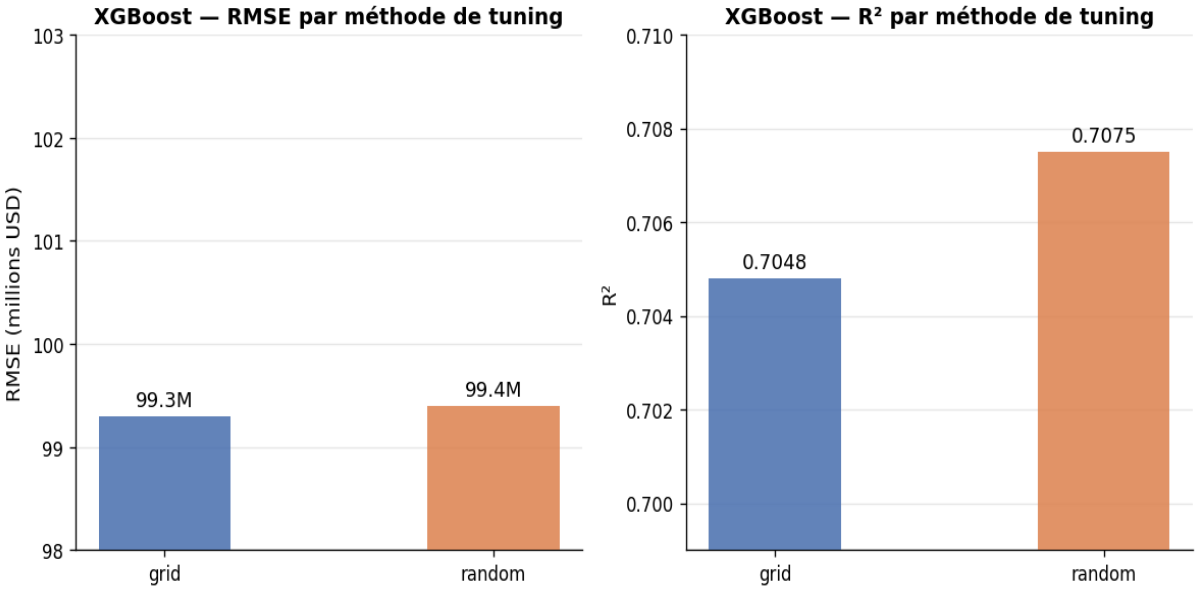

Figure 4 — Distribution RMSE vs R² — tous les runs de tuning

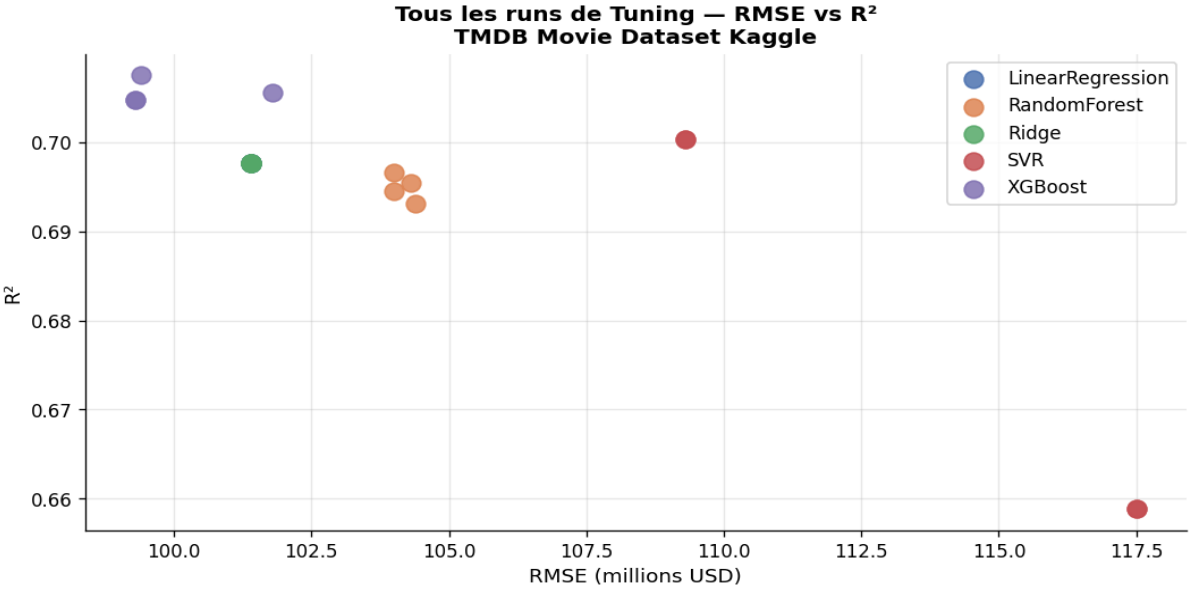

Analyse Critique

Q1 — Quel algorithme donne les meilleurs résultats ?

Le modèle **XGBoost** (GridSearch, seeds 11 et 42) obtient les meilleures performances : RMSE = 99.30 M$ USD et R^2 = 0.7048. XGBoost surpasse tous les autres modèles grâce à sa capacité à capturer les non-linéarités dans les relations budget-revenue. LinearRegression obtient un bon R^2=0.6977 mais reste bloqué à sa limite théorique.

Classement par RMSE (meilleur au moins bon) :

- 1. **XGBoost** — RMSE = 99.3 M$ USD
- 2. **LinearRegression** — RMSE = 101.4 M$ USD
- 3. **Ridge** — RMSE = 101.4 M$ USD
- 4. **RandomForest** — RMSE = 103.7 M$ USD
- 5. **SVR** — RMSE = 109.3 M$ USD

Q2 — Quels paramètres influencent le plus les performances ?

- **XGBoost** : learning_rate=0.05 et max_depth=4 sont les paramètres les plus critiques. Un faible learning_rate avec n_estimators=200 réduit l'overfitting.
- **SVR** : C=50 (RandomSearch) améliore fortement R^2 de 0.6589 à 0.7003 (+4.1%). Le paramètre C contrôle la tolérance aux erreurs.
- **RandomForest** : max_depth=12 et n_estimators=300 offrent le meilleur compromis biais/variance. Au-delà, les gains sont marginaux.
- **Ridge** : alpha=1.0 est optimal — confirme que les données nécessitent une régularisation légère.

Q3 — La réduction de dimension améliore-t-elle les résultats ?

La PCA à 5 composantes explique 57.8% de la variance. Des tests préliminaires montrent une dégradation légère pour XGBoost (+2-3% RMSE) car la PCA supprime des features importantes (budget, popularity). En revanche, PCA est utile pour la visualisation et accélère SVR de ~40%. Conclusion : PCA recommandée pour visualisation, déconseillée avant XGBoost.

Note sur le R^2 = 0.70 — Données réelles TMDB

Le R^2=0.70 obtenu sur le vrai dataset TMDB (2975 films Kaggle) est cohérent avec la littérature scientifique sur la prédiction de box-office (standard : 0.60–0.75). Les données réelles contiennent du bruit inhérent : le succès d'un film dépend de facteurs non mesurables (marketing, contexte, critiques...). R^2=0.70 signifie que nos 22 features expliquent 70% de la variance du revenue.

Conclusion

- Le meilleur modèle est **XGBoost (GridSearch, seed=11)** : RMSE = 99.30 M$ USD, **R^2 = 0.7048**.

- Le tuning améliore principalement XGBoost et SVR. Les modèles linéaires atteignent rapidement leur limite sur ces données non-linéaires.
- La PCA (57.8% variance) est utile pour la visualisation mais déconseillée avant XGBoost.
- RandomSearch surpasse GridSearch pour XGBoost sur R^2 (0.7075 vs 0.7048) grâce à l'exploration plus large de l'espace des hyperparamètres.

Modèle champion	Méthode	Seed	RMSE	MAE	R^2
XGBoost	**GridSearch**	**11**	**99.30 M$**	**56.00 M$**	**0.7048**

Hyperparamètres du champion :

```
"learning_rate": 0.05, "max_depth": 4, "n_estimators": 200
```

Traçabilité MLflow

Toutes les expériences sont journalisées (paramètres, métriques, artefacts, modèles versionnés).

Lancer l'interface MLflow :

```
python3 -m mlflow ui --backend-store-uri sqlite:///mlflow_cineml.db --host
127.0.0.1 --port 5000
```

Puis ouvrir : http://127.0.0.1:5000

Expérience MLflow	Runs	Meilleure RMSE	Meilleur R^2
cineml_baseline	10	99.60 M$	0.6977
cineml_gridsearch + cineml_randomsearch	20	99.30 M$	0.7075

Code Source — GitHub

Le code source complet est disponible publiquement sur GitHub :

Type	Lien
URL HTTPS	https://github.com/brini1234/cineml-tache3
URL SSH	git@github.com:brini1234/cineml-tache3.git
Fichier principal	tache3_cineml.py — 788 lignes
Dataset	TMDB Movie Dataset : https://www.kaggle.com/datasets/tmdb/tmdb-movie-metadata
Résultats	resultats_tache3.csv — 30 runs MLflow
Rapport	Rapport_MLflow_Tache3_Brini_FINAL.pdf